



信贷违约预测模型 与放贷审批线设计

阿里线上数据分析实习 · W1—W4 汇总

基于阿里天池信贷违约数据集

汇报人：王子安 / 交付日期 2026-09-28

金额口径中净息差 6%、回收率 30% 为模拟值

交付目标：给出一条可执行的放贷方案

W1

数据探索

100 万笔贷款、47 个字段
标签为是否违约
违约样本约占两成

W2

特征工程

编码、变换、创建、选择
输出 38 个建模特征
参数只在训练集上拟合

W3

建模与调优

随机搜索定参
调参前后同口径对照
LightGBM 胜出

W4

审批线与落地

方案① 单线扫描
方案② 逐笔期望定线
方案② 执行：三段分工

数据与质量：脏值逐项闭合，79.8 万行进入建模

798,498

清洗后可用行数

原始 80 万行 × 47 字段，删 1,502 行 (0.19%)

缺失值：22 列有缺失，按量级分三种处理

匿名 n0—n14 约 62 万格填中位数

就业年限 46,375 个填「未知」；6 列极少缺失删行

异常值：按业务规则定界，不按统计机械删

年收入 = 0 共 229 个，全是联合申请的主借人

额度使用率 > 100% 封顶；dti 越界删行

一致性：id 重复 0、fico 上下限倒挂 0；清洗后剩余缺失格 0

来源：报告 3.1—3.3 节；data/train_clean.csv、outputs/W1/data_quality_report.txt

子集	人数	用途
清洗后总量	798,498	7:2:1 分层切分
训练集	558,948	拟合模型参数
验证集	159,700	选择阈值与模型
测试集	79,850	全册成绩与金额
testA	200,000	无标签，不进本册

数据探索：违约占两成，年收入严重右偏




图 4-1 | 违约约占两成

违约 159,287 人，占 19.95%


类别不平衡，准确率会骗人，改用 AUC、KS

图 4-2 | 年收入：原始刻度 vs log1p 后

偏度 46.4 → 0.20，长尾压住；最高 1,099.9 万

变换后按 z-score 标准化，规则只在训练集拟合

图 4-3 | 其余五个核心变量：量纲从 0.9% 到 6.5 万，统一 z-score 标准化



相关性与分层：只有一对派生强相关，等级是最强的分层变量

图 5-1 | 违约组与正常组在同一批变量上的对比（年收入用 log 刻度）




图 5-2 | 两两相关系数：最强一对 金额 × 分期 0.95（派生），其余 $|r| \leq 0.46$





图 5-3 | A 级 6.0% → G 级 49.7%



读法：违约组利率 15.1% vs 12.2%、dti 19.7 vs 17.1、收入更低；金额 × 分期额 $r=0.95$ 是派生关系，其余 $|r| \leq 0.46$

特征工程：47 个原始字段加工为 38 个建模特征

47 个原始字段

38 个建模特征

编码

等级与子等级用序数编码
保留等级大小关系
地区用目标编码

变换

右偏变量做 log1p
再做 z-score 标准化
缺失值只在训练集拟合

创建

grade × dti
interestRate ×
loanAmnt
grade_dti_inter 进前五

选择

过滤法与嵌入法两路交叉
由 60 列筛到 38 个特征
包装法 RFE 成本高于收益

防泄漏：规则只在训练集上学

再套用到验证与测试
缺失值填充规则同理

图 6-1 | 特征数量与验证集 AUC





图 6-1 为验证集 AUC（调参后 LGB，38 个时 0.7294）。来源：报告 5.1—5.6 节、outputs/W4/feature_count_auc.csv

模型优化：换调参方法几乎不影响成绩，增益来自参数本身

图 7-1 | 16 组参数的训练集 5 折平均 AUC（每折 80% 训练集）



5 折分层交叉验证：分数可信

每折用 80% 训练集，标准差 ≤ 0.00071

最优 XGB 0.7247 / LGB 0.7249

16 组里最差一组也有 0.7167

图 7-2 | 三种方法等预算对照



方法差异可以忽略

同模型内三法最好成绩极差 < 0.0002

换参数的跨度 0.0124，是换方法的 80—110 倍

正式用随机搜索：库自带、可复现；贝叶斯慢 35%


模型选型：基线对照与等预算调参后选用 LightGBM

同口径对比五个单模型，LightGBM（调参后）最高

模型	验证集 AUC	单次训练耗时
逻辑回归（基线）	0.7189	—
随机森林（基线）	0.7198	—
XGBoost（基线）	0.7276	1.8 秒
XGBoost（调参后）	0.7286	4.6 秒
LightGBM（调参后）	0.7294	5.6 秒
投票集成	0.7276	44.7 秒
堆叠集成	0.7298	371.0 秒

验证集 AUC（159,700 人）为选型口径；耗时取同机单次训练

图 8-1 | 学习曲线：灰训练集、白验证集，末点贴合



被否掉的方案

网格 / 贝叶斯调参：等预算下与随机搜索等效
投票 / 堆叠：无实质提升，堆叠训练 371 秒
DeLong 检验：基线与投票的差异不显著

模型评估：排序可用于初筛，概率刻度需校准

三集 AUC 贴合，没有过拟合

训练 0.7432 / 验证 0.7294 / 测试 0.7249

KS 0.3269，高于常用 0.30 门槛

可用于风险排序与辅助人工审核
AUC 0.72 不足以支撑全自动放款

概率刻度偏高一倍以上

平均预测 0.4495，实际违约率 0.1995
Platt 校准后平均 0.1993
Brier 由 0.2106 降到 0.1424，AUC 不变

图 9-5 | SHAP：模型最看重的五个特征




图 9-1 | ROC, AUC 0.7249




图 9-2 | PR, 精确率 0.325 (召回 $\geq$ 1%)





图 9-3 | 判违约者三分之一属实


真正常	41,630 52.1%	22,291 27.9%
	5,179 6.5%	10,750 13.5%
真违约	判正常	判违约

图 9-4 | 校准后贴近实际违约率



名单头部：分数最高的 10% 覆盖 24.1% 的违约者

图 10-1 | 名单头部占比与违约者捕获率 (测试集 79,850 人)



24.1%

前 10% 捕获的违约者占比

48.1%

这批人自身的违约率

54.6%

前 30% 覆盖的违约者占比

前 10% 是随机抽取的 2.41 倍；捕获率只看排序，与概率刻度无关。来源：报告 9.1 节

时间外验证：排序能力基本保持，概率刻度要重新标定

为什么切这一刀：随机切分把同一段行情分到两边，成绩偏乐观；按日期切（训练 66.5 万 / 评估 12.5 万）才是上线时的样子

图 11-1 | 按放款日期切：训练用 2016-12 前，测试用 2017 年起



排序能力：基本保持

AUC 0.7279 → 0.7184

KS 0.3300 → 0.3190

前 10% 捕获率 24.1% → 21.7%

◆ 图 11-2 | 十分位：原始输出与实际违约率，逐组上升

最低一组：预测 12.0% / 实际 3.8%



概率刻度：未跟上行情

违约率 19.9% → 22.3%

模型平均输出 0.450 → 0.459；0.5 线拒人比例 41.9% → 43.9%

读法：0.7279 是本套切分的随机对照，与第 9 页测试集不是同一批样本；2018-07 后 8,980 笔已剔除 | 报告 9.6 节

放贷方案 ①

单线扫描：一条线管所有人，0.553 处最赚

审批线是一条概率门槛，达到线的人拒贷。放贷方案有两个，本页是方案①：全批设一条线；方案②按每笔的账定线

图 12-1 | 阈值扫描：白线为拦截率（真违约里被拦下的比例），橙线为被拒者精确率（被拒的人里真违约的比例）




图 12-2 | 阈值与金额：0.553 处比全放多 4,157 万元（回看，要数历史答案，用来挑线）、4,259 万元（期望，线上能算）



期望口径：全放 2,085 万元；0.50 拒 33,041 人 6,155 万元；0.553 最赚 6,344 万元。来源：报告 10.1—10.2 节

放贷方案 ②

按期限定线：逐笔期望利润，3 年期 0.50、5 年期 0.62

每 1 元贷款的期望利润 = $(1 - p) \times \text{净息差} \times \text{期限} - p \times (1 - \text{回收率})$ ，为正就批

从每笔自己的账出发：金额按校准概率逐笔算，不用事后结果；净息差 6%、回收率 30% 为模拟值

本批只有 3 年期与 5 年期两种贷款

3 年期

阈值 ≥ 0.50 拒

校准概率轴 0.2045；这批人平均利率 12.1%

5 年期

阈值 ≥ 0.62 拒


校准概率轴 0.3000；这批人平均利率 16.8%

拒 28,078 人 (35.2%)

期望利润 6,611 万元，比最优单一线多 267 万元

同一把尺子：期望利润 6,611 vs 单线 6,344 万元，多 267 万元；代价是出两张评分表。来源：报告 10.2 节

图 13-1 | 换口径后这套规则会拒掉多少人



落地形态：被判拒的 28,078 人不全拒，贴线的转人工复审

规则不动，改的是拒掉的人怎么办：贴线的 8,697 人转人工复审，更上面的 19,381 人直接拒

直接放行 64.8%

人工复审 10.9% 直接拒绝 24.3%

分工	人数	占测试集	该段模型预估违约率
直接放行	51,772	64.8%	12.1%
人工复审	8,697	10.9%	25.9%
直接拒绝	19,381	24.3%	38.2%

复审带取线上方 20% 以内，占被拒人数的 31.0%；带宽按复核产能调

贴线的人模型最没底，又可能藏着被误拒的好客户，业务上不自动拒、转人工复审

上线前提：真实财务口径与被拒人群观测

三类局限

数据

样本违约率 19.95%，高于真实客群（通常低于 5%）
n0 到 n14 有信号但没有业务含义，监管上难解释
只有一期数据，时间外验证只切了一刀

模型

AUC 0.7249 适合排序初筛与辅助人工审核
金额里的「避免的坏账」始终是估计值
金额只属于这一批，能搬走的是排序与线

业务观测

被拒客户后来能不能还上，模型永远观测不到

下一步（四条）

- ① 用机构真实财务口径重算全部金额
 - ② 按月做 walk-forward 回测
 - ③ 小流量放行或影子测试，标定被拒人群
 - ④ 补齐可解释特征，满足合规要求
- ③ 的观测要靠放行才能拿到，只能小流量做

推进顺序：先按 0.55 把单一线跑起来，同时推进财务口径标定

口径与审批系统改造都到位后，再切到按期限的两条线；改造成本按每 100 亿元年放款额多 2,319 万元来比